

보이스피싱 탐지를 위한 개인정보 마스킹 환경의 RAG 시스템 설계

Study Plan for Retrieval-Augmented Voice Phishing Detection under PII-Masked Data Conditions

김병욱
경희대학교 컴퓨터 공학과
bwook00@khu.ac.kr

요약

보이스피싱은 기관 사칭, 가족 사칭, 대출 사기, 악성 애플리케이션 설치 유도 등 다양한 형태로 나타나며, 실제 통화나 문자 대화 안에서 맥락적으로 탐지되어야 한다. 본 기초조사서는 보이스피싱 탐지를 위한 Retrieval-Augmented Generation(RAG) 기반 시스템을 설계하고, 개인정보 마스킹이 검색 성능에 미치는 영향을 분석하기 위한 연구 계획을 정리한다. 본 연구에서는 원본 데이터 기반 Naive RAG, 마스킹 데이터 기반 Naive RAG, 마스킹 데이터 기반 Advanced RAG의 세 조건을 비교할 예정이다. 이를 위해 보이스피싱 패턴을 유형별로 정리하고, 핵심 사기 구조를 기준으로 seed scenario를 설계한 뒤, 대화 길이, 피해자 반응, 정보 노출 시점, 압박 강도 등 증강 변수를 조합해 corpus를 생성할 계획이다. 또한 개인정보 보호 요구를 반영한 masked corpus를 별도로 구성하고, 동일한 QA 평가 셋을 사용해 세 실험 설정을 비교할 예정이다.

1. 서론

보이스피싱은 전화, 문자, 메신저 등 다양한 채널을 통해 피해자를 기만하고 금전 이체, 개인정보 입력, 원격 제어 애플리케이션 설치와 같은 행동을 유도하는 대표적인 사회공학 공격이다. 이러한 공격은 단순한 키워드 일치만으로는 충분히 탐지하기 어렵고, 발화 흐름과 요구 행동, 심리적 압박의 전개 구조를 함께 이해해야 한다. 따라서 검색 기반의 문맥 보강과 생성 모델의 판단을 결합하는 RAG 접근은 보이스피싱 탐지에 유의미한 방법론이 될 수 있다.

그러나 실제 보이스피싱 시나리오에는 이름, 주소, 사건번호, 계좌번호, 기관명, 은행명 등 검색에 직접적인 단서가 되는 식별 정보가 빈번하게 등장한다. 이러한 정보는 검색 정확도를 높이는 데 기여할 수 있지만, 개인정보 보호 관점에서는 그대로 활용하기 어렵다. 특히 개인정보를 비식별화하거나 마스킹할 경우, 검색 단계에서 사용 가능한 단서가 줄어들어 retrieval 품질이 저하될 가능성이 있다.

본 연구는 원본 데이터 기반 Naive RAG, 마스킹 데이터 기반 Naive RAG, 마스킹 데이터 기반 Advanced RAG의 세 가지 설정을 비교하는 실험을 설계한다. 기초조사 단계에서는 실험 결과를 제시하기보다, 데이터 생성 전략과 패턴 추출 및 증강 설계를 중심으로 향후 연구 수행의 타당성과 구체성을 정리하는 데 목적을 둔다.

2. 관련 연구 및 배경

RAG는 외부 문서 집합에서 관련 문맥을 검색한 뒤, 이를 기반으로 생성 모델이 응답 또는 판단을 수행하도록 하는 구조이다. 이러한 방식은 지식 한계와 환각 문제를 줄이는 데 활용되어 왔으며, 질의응답과 분류, 문서 기반 추천 등 다양한 작업에 적용되어 왔다 [1]. 보이스피싱 탐지 역시 특정 패턴과 문맥 단서를 기반으로 이루어진다는 점에서, 적절한 검색 문맥을 제공하는 RAG 구조가 유효할 가능성이 있다.

한편 보이스피싱은 기관 사칭형, 가족·지인 사칭형, 대환대출 사칭형, 원격제어 앱 설치 유도형, 배송 사칭형 등 다층적인 유형으로 전개된다. 따라서 탐지용 데이터셋을 구성할 때는 표면 문장만 달린 예시를 반복하는 것이 아니라, 각 유형의 핵심 사기 구조를 추출하고 이를 기반으로 다양한 시나리오를 설계할 필요가 있다. 또한 실제 연구 적용을 위해서는 개인정보 보호 요구를 함께 고려해야 하므로, 원본 데이터와 마스킹 데이터를 병행 설계하는 접근이 필요하다.

국내 공공기관과 금융기관의 보이스피싱 대응 안내 자료에서는 기관 사칭, 링크 접속 유도, 앱 설치 유도, 계좌 이체 요구와 같은 신호들이 반복적으로 제시된다 [2]-[4]. 본 연구는 이러한 안내 자료를 바탕으로 패턴 체계를 정리하고, 한국어 환경에서 자연스러운 시나리오를 구성하는 방향으로 데이터를 설계할 예정이다.

3. 연구 문제 및 목표

본 연구는 두 가지 목표를 중심으로 설계한다. 첫째, 개인정보가 유지된 원본 데이터 기반 Naive RAG와 비교할 때, 개인정보가 마스킹된 데이터 기반 Naive RAG의 성능이 유의미하게 저하되는지를 확인할 예정이다. 이는 이름, 주소, 기관명, 계좌번호, 사건번호 등 식별 정보가 retrieval 단계에서 강한 단서로 작동할 수 있다는 가정에 기반한다.

둘째, 마스킹된 데이터 환경에서 pattern extraction, hybrid search, reranker를 포함한 Advanced RAG를 설계하여, 단순 lexical retrieval의 한계를 보완할 계획이다. 이를 통해 마스킹으로 인해 감소한 검색 성능이 원본 데이터 기반 기준선에 어느 정도까지 회복될 수 있는지 검토할 예정이다.

4. 연구 방법 및 수행 계획

4.1 전체 연구 설계

본 연구는 데이터 설계 단계, baseline RAG 설계 단계, masked 환경 비교 단계, advanced retrieval 설계 단계로 나누어 수행할 예정이다. 먼저 보이스피싱 유형을 구조적으로 정리한 뒤, 유형별 seed scenario를 설계하고 이를 기반으로 원본 corpus를 생성할 계획이다. 이후 동일한 corpus에 대해 개인정보 마스킹 규칙을 적용한 masked corpus를 구성하고, 두 corpus를 각각 Naive RAG의 검색 대상 문서 집합으로 사용할 예정이다. 마지막으로 마스킹 데이터 환경에서 pattern extraction과 hybrid retrieval, reranking을 추가한 Advanced RAG를 설계하여 성능 회복 가능성을 검증할 계획이다.

4.2 보이스피싱 패턴 추출 계획

데이터 생성의 출발점은 보이스피싱 패턴 추출 단계로 설정한다. 본 연구는 공식 보이스피싱 대응 기관 자료와 금융사기 안내 자료를 검토하여, 실제 한국어 환경에서 반복적으로 등장하는 사기 구조를 유형화할 예정이다. 이때 단순히 표면 주제만 나누는 것이 아니라, 공격자의 목적, 피해자 설득 방식, 심리적 압박 순서, 최종 유도 행동을 중심으로 패턴을 정의할 계획이다.

우선 기관 사칭형, 고립 유도형, 가족·자녀 사칭형, 납치 병자 AI 음성형, 대환대출 사칭형, 선입금 요구형, 악성 앱 원격제어형, 카드 배송 사칭형, 법원 등기우편 사칭형, 스미싱·큐싱 연계형과 같은 주요 패턴을 중심으로 유형 체계를 설계할 예정이다. 본 연구에서는 각 패턴의 핵심 사기 구조를 발화 전개 단위에서 정의하고, 각 샘플이 하나의 주 패턴을 명확히 가지게 설계할 예정이다.

4.3 Seed Scenario 설계 계획

패턴 정의가 끝나면, 각 패턴별로 seed scenario를 설계할 예정이다. seed scenario는 이후 증강을 위한 원형 데이터로 사용되므로, 단순 예문 수집이 아니라 실제 통화나 메시지 전개처럼 맥락이 이어지는 시나리오 형

태로 구성할 계획이다. 각 seed scenario에는 공격자의 발화뿐 아니라 피해자의 의심, 반박, 질문, 망설임 등을 포함시켜, 후속 증강에서 상호작용 구조를 확장할 수 있는 기반을 마련할 예정이다.

또한 seed 단계부터 이름, 기관명, 은행명, 주소, 사건번호, 계좌번호, 링크, 금액 등 검색 단서가 될 수 있는 식별 요소를 의도적으로 설계할 계획이다. 이는 후속 마스킹 단계에서 단서 제거 전후의 retrieval 차이를 관찰하기 위한 것이다. 다만 실제 민감정보를 사용하는 대신, 현실감은 유지하되 가상의 정보로 구성하여 개인정보 침해 위험을 피할 계획이다.

4.4 데이터 증강 및 corpus 생성 계획

본 연구는 패턴 수를 무한히 늘리기보다, 각 패턴 내부의 대화 구조를 충분히 다양화하는 전략을 택할 예정이다. 이를 위해 공통 증강 변수와 패턴별 핵심 변수를 분리해 설계한다. 공통 증강 변수로는 대화 길이, 피해자 의심 정도, 개인정보 노출 시점, 압박 강도, 대화 종료 방식, 맥락 환경, 언어 스타일, 잡음 수준 등을 활용할 계획이다.

각 패턴의 설명력을 높이는 보조 변수는 1~2개 수준으로 제한할 계획이다. 예를 들어 기관 사칭형에는 위협 강도와 자산 요구 방식을, 가족 사칭형에는 핑계 유형과 송금 논리를, 악성 앱 원격제어형에는 설치 흐름과 기기 통제 수준을 추가 변수로 설계할 예정이다. 이는 증강 조합이 지나치게 복잡해지는 것을 방지하면서도, 각 패턴의 핵심 차이를 유지하기 위한 선택이다.

또한 증강은 문장 치환 수준이 아니라 구조 변형 중심으로 수행할 계획이다. 동일 패턴 안에서도 어떤 시나리오는 초반에 개인정보가 빠르게 노출되도록 하고, 다른 시나리오는 중반 또는 후반에 노출되도록 조정할 예정이다. 일부 시나리오에서는 피해자가 쉽게 응하는 흐름을, 다른 시나리오에서는 반박과 의심이 반복되는 흐름을 넣을 계획이다. 긴 대화의 경우에는 단순 filler를 늘리는 대신, 확인, 반박, 재안내, 종결과 같은 블록을 추가하여 실제 대화 리듬을 반영할 예정이다.

수량 측면에서는 패턴별 샘플 수와 길이 분포를 일정 수준 통제할 계획이다. 각 패턴에 대해 short, medium, long 길이 구간을 나누고, 패턴 내부에서도 길이와 의심 수준, 종료 방식의 편중이 발생하지 않도록 분포를 조정할 예정이다. 다만 모든 변수의 완전 균형 조합을 맞추기보다, 특정 조합만 반복되지 않도록 관리할 계획이다.

4.5 원본 corpus와 masked corpus 설계 계획

원본 corpus는 retrieval에 도움이 되는 식별 단서를 일정 수준 포함한 상태로 설계할 예정이다. 이는 baseline Naive RAG가 활용할 수 있는 문맥 단서를 충분히 제공하기 위한 것이다. 특히 보이스피싱 시나리오에서는 공격자가 피해자 이름, 은행명, 사건번호, 기관명, 링크, 금액, 주소 등 구체적인 단서를 활용해 신뢰를 형성하는 경우가 많으므로, 원본 corpus는 이러한 특성을 반영한 형태로 구성할 계획이다.

이후 동일한 원본 corpus에 대해 masked corpus를 별도로 생성할 예정이다. masked corpus에서는 이름, 자녀 이름, 지인명, 주소, 은행명, 직장명, 학교명, 기관명, 앱명, 사건번호, 계좌번호, 링크, 금액 등 주요 식별 단서를 정해진 토큰으로 치환하는 규칙을 적용할 계획이다. 이 과정은 개인정보 보호를 위한 비식별화 처리이면서 동시에 retrieval cue 축소 효과를 관찰하기 위한 핵심 실험 조작으로 기능할 것이다.

4.6 QA 데이터셋 및 평가 계획

평가를 위한 QA 데이터셋은 보이스피싱 시나리오, 실제 금융 통화 맥락의 정상 시나리오, 그리고 맥락과 무관한 일반 텍스트의 세 가지 source로 설계할 예정이다. 보이스피싱 시나리오는 positive sample로 사용하고, 실제 은행 상담 흐름을 따르되 사기 유도는 없는 bank_call 시나리오는 hard negative로 구성할 계획이다. 또한 일상 대화, 공지, 배송 안내 등으로 이루어진 irrelevant 시나리오는 easy negative로 포함하여, 단순 맥락 불일치와 금융 맥락 혼동을 분리해 관찰할 수 있도록 설계할 예정이다.

모든 QA 샘플에는 동일한 질문을 사용할 계획이다. 예를 들어 "이 텍스트는 보이스피싱으로 판단해야 하는가? yes or no로 답하라."와 같은 고정 질문을 사용함으로써, prompt variation을 줄이고 retrieval 조건에 따른 차이를 더 직접적으로 비교할 수 있도록 할 예정이다.

4.7 세 가지 RAG 실험 설정 계획

첫 번째 실험은 원본 corpus를 대상으로 하는 Naive RAG이다. 이 설정은 개인정보가 유지된 조건에서 lexical retrieval 기반 검색이 어느 수준의 기준 성능을 형성하는지 확인하기 위한 baseline으로 사용될 예정이다. 두 번째 실험은 masked corpus를 대상으로 하는 Naive RAG이다. 이 설정은 검색 구조 자체는 동일하게 유지하되, 문서 내 식별 단서만 축소된 조건에서 retrieval 품질이 얼마나 감소하는지 확인하기 위한 비교군으로 활용할 예정이다.

세 번째 실험은 masked corpus를 대상으로 하는 Advanced RAG이다. 이 단계에서는 단순 keyword 기반 검색을 넘어, 패턴 추출을 통해 질의와 문서를 구조적 특징 공간에서 연결하고, sparse 신호와 dense 또는 패턴 기반 신호를 결합하는 hybrid search를 설계할 계획이다. 이후 상위 후보 문서에 대해서는 reranker를 적용하여, 마스킹으로 인해 약화된 lexical cue를 보완할 수 있는지 검토할 예정이다.

5. 기대 효과 및 향후 계획

본 연구는 보이스피싱 탐지에서 개인정보 보호와 검색 성능 사이의 긴장을 구조적으로 다룬다는 점에서 의의를 가진다. 특히 개인정보 마스킹이 retrieval 단계에서 어떤 비용을 발생시키는지 정량적으로 검토하고, 패턴 중심의 검색 강화 기법이 이러한 비용을 어느 정도 상쇄할 수 있는지 살펴볼 수 있을 것으로 기대한다.

또한 데이터 생성 측면에서는 단순 문장 수집이 아니라 패턴 추출과 구조 기반 증강을 결합한 corpus 설계 절차를 제안함으로써, 향후 유사한 사회공학 공격 탐지 연구에도 적용 가능한 데이터 구축 프레임워크를 마련할 수 있을 것으로 본다. 이후 연구에서는 pattern extraction schema를 더욱 정교화하고, hybrid retrieval의 조합 방식과 reranker 설계 기준을 구체화하며, 실제 실험 결과를 바탕으로 각 구성 요소의 기여도를 분석할 계획이다.

참고문헌

- [1] Patrick Lewis et al., "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks," 2020.
- [2] 금융위원회, 보이스피싱 대응 관련 안내 자료, <https://www.fsc.go.kr/no010101/86250>
- [3] 한국인터넷진흥원(KISA), 보이스피싱 및 스미싱 대응 안내 자료, <https://www.kisa.or.kr/1020601>
- [4] 하나은행, 금융사기 및 보이스피싱 예방 안내 자료, https://www.kebhana.com/cont/news/news01/1496774_115430.jsp