

보이스피싱 탐지를 위한 개인정보 마스킹 환경의 RAG 시스템 설계

김병욱 · 경희대학교 전자공학과
졸업프로젝트 최종 발표

Motivation

PREVIOUS PROTOTYPE

Voice Phishing MCP Server

Claude Code Hackathon에서 보이스피싱 탐지
MCP server prototype을 만들었다.

**작동하는 탐지 시스템을 만든 뒤,
하나의 현실적인 질문이 남았다.**

**“민감한 통화 transcript를 다룰 때,
그래도 개인정보 마스킹을 적용해야 할
까?”**

이 프로젝트는 그 질문에서 출발해, 마스킹이 RAG 기반
보이스피싱 탐지 성능에 미치는 영향을 실험적으로 확인
했다.

핵심 질문

개인정보를 마스킹해도 RAG 기반 보이스피싱 탐지 성능을 유지할 수 있을까?

PROBLEM

Masking
식별 단서 제거


IMPACT

Retrieval
검색 근거 약화

SOLUTION

Advanced RAG
구조적 패턴 활용

연구 범위



SCOPE

STT 이후 생성된 **통화 transcript**를 입력으로 사용

EXCLUDED

STT 모델 자체의 성능 평가는 실험 범위에서 제외

FOCUS

개인정보 마스킹이 RAG 탐지 성능에 미치는 영향 분석

음성 처리 시스템이 아니라, 마스킹된 transcript 환경에서의 RAG 탐지 문제에 집중했다.

왜 마스킹이 문제가 되는가?

ORIGINAL TRANSCRIPT

김하늘 씨 맞으신가요?
국민은행과 카카오뱅크에 보안 점검 이력이 있습니다.
문자로 전용 페이지를 보내드릴 테니
보호 모듈을 설치해 주세요.

MASKED TRANSCRIPT

[이름] 씨 맞으신가요?
[기관명]과 [기관명]에 보안 점검 이력이 있습니다.
문자로 전용 페이지를 보내드릴 테니
보호 모듈을 설치해 주세요.

Naive RAG는 이름, 기관명, 계좌, 주소처럼 query와 corpus를 이어주던 검색 연결 단서를 잃는다.

실험 데이터 예시: Voicephishing

POSITIVE SAMPLE

고객센터: 금융보호지원센터 이상거래 확인팀입니다.

고객센터: 등록된 성함이 김하늘 씨 맞으신가요?

고객센터: 국민은행과 카카오뱅크에 보안 점검 이력이 남아 있습니다.

피해자: 제가 한 건 아니에요. 갑자기 왜 이런 확인을 하시죠?

고객센터: 전용 페이지로 접속해 보호 모듈을 설치해 주세요.

고객센터: 설치 후 표시되는 6자리 확인번호를 입력해 주시면 계정 보호가 완료됩니다.

전용 페이지 접속

보호 모듈 설치

인증번호 입력 요구

이상거래/보호 절차 명목

겉으로는 금융 보안 안내처럼 보이지만, 실제로는 링크·앱 설치·인증번호 입력을 유도한다.

실험 데이터 예시: Hard Negative

BANK CALL HARD NEGATIVE

상담원: 최근 비정상 접속 시도가 확인되어 보호성 제한 상태입니다.

고객: 어떤 확인을 하면 되나요?

상담원: 공식 앱의 알림센터에서 상태를 직접 확인해 주세요.

상담원: 인증번호는 절대 말씀해 주실 필요 없습니다.

상담원: 대표번호로 다시 걸어 주시면 부서 확인 후 안내드릴 수 있습니다.

상담원: 필요 시 가까운 영업점 방문으로 전환하시면 됩니다.

공식 앱 직접 확인

인증번호 공유 금지

대표번호 재연락 가능

영업점 방문 안내

금융·보안 표현은 비슷하지만, 사기 유도 행동이 없기 때문에 hard negative로 사용했다.

Dataset Design

1,000

augmented hard
benchmark

500

voicephishing positive

500

bank call hard negative

Irrelevant sample은 너무 쉽게 no로 분류되는 경우가 많아 최종 주요 비교에서는 제외했다.

Easy negative

일상 대화, 날씨, 음식 주문 → 너무 쉽게 no

Hard negative

정상 금융 보안 안내 → 표현은 유사하지만 사기 행동은
없음

비교한 세 가지 Pipeline




같은 benchmark에서 Original → Masked 하락과 Advanced 회복을 비교

Two Evaluation Tracks

TRACK A · RETRIEVAL-ONLY



TRACK B · END-TO-END RAG



왜 Retrieval-only도 중요한가?

Cost

매 통화마다 LLM API 호출
비용 발생

Latency

통화 중 경고에는 즉시성 필요

Battery

온디바이스 LLM은 연산·배
터리 부담

Privacy

transcript 외부 전송 부담

LLM 없이도?

Input

통화
transcript

Signal

BM25 /
similarity
score


Rule

threshold 기
반 yes/no

Retrieval-only는 경량 탐지 가능성과 마스킹이 검색 단계
에 미치는 영향을 동시에 보여준다.

Advanced RAG: 핵심 아이디어

개인정보가 사라져도, 사기 행위의 구조는 남아 있다.



MASKED NAIVE RAG

- 이름·기관명·계좌번호 검색 단서 약화
- query-context 연결 근거 부족
- 단순 score 기준에서 positive recall 하락

MASKED ADVANCED RAG

기관 사칭

이상거래 명목

링크·앱 설치

인증번호 요구

송금 유도

정상상담 guard

Retrieval-based Result


Pipeline	Accuracy			
Original Naive RAG	0.8210	Original		0.821
Masked Naive RAG	0.5410	Masked		0.541
Masked Advanced RAG	0.9110	Advanced		0.911

LLM 없이 retrieval score와 threshold만으로 평가했다.

마스킹 후 Naive RAG는 검색 연결 단서 손실로 크게 하락했고, Advanced RAG는 구조적 패턴 기반으로 회복했다.

End-to-End RAG Result

Pipeline	Accuracy
Original RAG	0.8940
Masked RAG	0.5130
Masked Advanced RAG	0.9530



LLM 최종 판단까지 포함해도 동일한 경향이 나타났다: Masked Naive 하락 → Advanced RAG 회복.

Sanity Check


✓ **Label balance: voicephishing 500 / bank_call 500**

✓ **Transcript 내 명시적 label leakage 없음**

✓ **동일 source sample 직접 retrieval 제외**

✓ **대화 turn 수 중앙값 유사**

✓ **bank_call도 금융/보안 표현 포함**



평가셋은 완전한 외부 실데이터가 아니라 seed scenario 기반 증강 benchmark이므로, 결과는 hard-negative 조건에서의 비교 evidence로 해석했다.

결론

1 개인정보 마스킹은 RAG의 검색 연결 단서를 약화시켜 성능 저하를 만들었다.

2 Retrieval-only 평가는 경량 탐지 가능성과 검색 단계 영향 분석에 유용했다.

3 End-to-end RAG에서도 masked naive의 성능 하락이 확인되었다.

4 Advanced RAG는 개인정보 단서 대신 보이스피싱 구조적 패턴을 활용해 masked 환경의 성능을 회복했다.

한계 및 향후 과제

LIMITATIONS

- 1000개 benchmark는 seed scenario 기반 증강 데이터
- 실제 통화 데이터 기반 검증은 추가 필요
- 보이스피싱/정상 금융 상담 유형 확장 필요

FUTURE WORK

- 실제 STT noise 반영 확대
- Advanced RAG 구성 요소별 ablation
- 실시간 탐지 threshold calibration
- 데모 UI 또는 경고 시스템 연결

Q&A

GitHub: github.com/bwook00/Phishing_Call_Detector

감사합니다.

왜 마스킹이 문제가 되는가?—

Two Evaluation Tracks—

왜 Retrieval-only도 중요한가?—

Advanced RAG: 핵심 아이디어—

Retrieval-based Result